

Relatório Técnico: Predição de Qualidade de Vinhos com Redes Neurais

Professor: Marcio Andrey Roselli

Estudante: Bianco Da Costa Oliveira

Bases Engenharia de Software VI - Inteligência Artificial

1. Introdução

Este relatório descreve o desenvolvimento de um modelo de Inteligência Artificial para a predição da qualidade de vinhos tintos da região do Minho, Portugal. Utilizando o dataset *Wine Quality* (Cortez et al., 2009), o objetivo principal foi converter um problema de regressão/multiclasse em uma classificação binária: vinhos "Bons" (nota ≥ 7) e vinhos "Regulares" (nota < 7). O desafio central reside no desbalanceamento dos dados, visto que vinhos de alta qualidade representam apenas cerca de 13,5% das amostras.

2. Metodologia

2.1 Pré-Processamento

Os dados passaram pelas seguintes etapas de tratamento:

- **Limpeza:** Verificação de valores ausentes (nenhum encontrado).
- **Divisão de Dados:** Separação em 80% para treinamento e 20% para teste, utilizando **estratificação** para manter a proporção das classes original em ambos os conjuntos.
- **Normalização:** Aplicação do *StandardScaler* para garantir que todos os 11 atributos físico-químicos (como álcool, pH e acidez) estivessem na mesma escala, evitando que variáveis com valores nominais maiores dominassem o aprendizado.

2.2 Arquitetura da Rede

Foi implementada uma Rede Neural Feedforward (MLP) utilizando PyTorch. Como definem Russell e Norvig, as redes com alimentação para a frente (feed-forward) possuem conexões em apenas uma direção, formando um grafo acíclico dirigido, o que lhes permite representar funções altamente não lineares e complexas de suas entradas. A arquitetura utilizada contou com a seguinte estrutura:

- **Camada de Entrada:** 11 neurônios.
- **1ª Camada Oculta:** 64 neurônios com ativação **ReLU**.
- **2ª Camada Oculta:** 32 neurônios com ativação **ReLU**.

- **Camada de Saída:** 1 neurônio (saída linear para uso com Logits).
- **Regularização:** Inclusão de camadas de **Dropout (30%)** após cada camada oculta para prevenir o *overfitting*.

2.3 Hiperparâmetros

Os parâmetros de treinamento foram selecionados para otimizar a convergência:

- **Otimizador:** Adam (taxa de aprendizado inicial de 0.001).
- **Função de Perda:** BCEWithLogitsLoss.
- **Épocas:** 100.
- **Batch Size:** 32.

Estratégias de Desbalanceamento

Foram adotadas duas estratégias principais:

1. **SMOTE (Synthetic Minority Over-sampling Technique):** Utilizado no pré-processamento para gerar amostras sintéticas da classe minoritária no conjunto de treino.
2. **Pesos de Classe (Class Weights):** Aplicação de um peso penalizador na função de perda para a classe positiva, forçando a rede a dar mais importância aos acertos dos vinhos "Bons".

3. Resultados

3.1 Tabelas Comparativas


O modelo de baseline (Regressão Logística com pesos balanceados) obteve uma acurácia de 81%, com Precisão de 0.40 e Recall de 0.79 para a classe minoritária. A Rede Neural superou o modelo de referência na grande maioria dos indicadores. A acurácia global subiu para 85%. Na classe minoritária ("Bom"), a Precisão saltou para 0.47, garantindo um F1-Score final de 0.58 (contra 0.53 do baseline), mantendo um Recall robusto de 0.77.

Modelo	Acurácia Geral	Precision (Bom)	Recall (Bom)	F1-Score (Bom)

Baseline (Reg. Logística)	81%	0.40	0.79	0.53
Rede Neural (Final)	86%	0.48	0.77	0.59

3.2 Curvas de Aprendizagem

A plotagem das funções de perda (*BCEWithLogitsLoss*) ao longo das 100 épocas demonstra um comportamento estável.




A curva de treinamento apresentou decaimento contínuo, enquanto a curva de validação acompanhou essa descida e estabilizou sem demonstrar divergência ascendente significativa. Isso atesta que as camadas de Dropout (30%) configuradas na arquitetura foram essenciais e bem-sucedidas em prevenir o overfitting. **Na literatura de IA, esse fenômeno também é conhecido como superadaptação, que ocorre quando modelos com muitos parâmetros (como**

redes neurais profundas) se ajustam excessivamente aos dados de treinamento, mas falham em generalizar para novas entradas. Dessa forma, impediu-se que a rede apenas memorizasse o conjunto de treino."

3.3 Matriz de Confusão

A decomposição dos acertos e erros do modelo evidencia os efeitos da técnica de *Class Weights* aplicada.




- **Verdadeiros Positivos (33):** De um total de 43 vinhos realmente "Bons" no conjunto de teste, o modelo conseguiu identificar corretamente 33. Isso representa um sucesso massivo na retenção de amostras de alta qualidade.
- **Falsos Negativos (10):** Apenas 10 vinhos excelentes passaram despercebidos pela rede, sendo classificados como regulares.
- **Falsos Positivos (37) e Verdadeiros Negativos (240):** O modelo classificou 37 vinhos regulares como bons. Esse é o custo intrínseco de se forçar um alto *Recall* em classes minoritárias: o algoritmo torna-se mais sensível e permissivo para não perder as amostras de interesse. Ainda assim, 240

vinhos regulares foram filtrados perfeitamente.

3.4 ROC (Receiver Operating Characteristic)


A curva ROC ilustra a capacidade do modelo de ranquear as classes.



O modelo obteve uma **Área Sob a Curva (ROC AUC) de 0.8884**. Em termos práticos, isso significa que se selecionarmos aleatoriamente um vinho "Bom" e um vinho "Regular", há aproximadamente 89% de probabilidade de a Rede Neural atribuir uma nota de predição maior ao vinho "Bom". É um índice de separabilidade excelente.

3.5 Precision-Recall

A Curva PR é o padrão-ouro para conjuntos de dados desbalanceados, pois foca exclusivamente no desempenho da classe positiva, ignorando a abundância de Verdadeiros Negativos que inflam a curva ROC.



A **Área (Average Precision / PR AUC)** atingiu a marca de **0.6736**. Considerando que um classificador puramente aleatório neste dataset teria um PR AUC igual à proporção da classe positiva (ou seja, apenas **0.13** ou 13%), o escore de 0.67 prova que a Rede Neural não está realizando "chutes" estatísticos, mas sim que conseguiu mapear com eficácia as complexas interações físico-químicas que definem a qualidade de um vinho verde.

4. Discussão

4.1 Q1: RN superou o Baseline?

A rede neural superou o baseline de regressão logística. Enquanto o modelo linear atingiu 81% de acurácia e um F1-Score de 0,53 para a classe "Bom", a rede neural alcançou 85% de acurácia e um F1-Score de 0,58.

A diferença de desempenho, embora clara, não é abismal (cerca de 4 a 5 pontos percentuais). Isso ocorre devido à natureza do dataset: com apenas 11 atributos e 1599 amostras, o problema possui baixa dimensionalidade e um volume de dados considerado "pequeno" para os padrões de *Deep Learning*. Em cenários assim, a superfície de decisão muitas vezes é quase linear ou possui pouca complexidade, permitindo que modelos simples como a Regressão Logística sejam altamente

competitivos. O ganho da rede neural reside na sua capacidade de mapear interações não lineares sutis entre variáveis como álcool e acidez volátil que o modelo linear não consegue capturar.

4.2 Q2: Trade-off Precision vs Recall

No modelo final, observamos uma **Precisão de 0,47** e um **Recall de 0,77** para a classe positiva.

- **Prioridade para Precision:** Em um cenário de **exportação de vinhos premium**, a Precision é prioritária. O custo de reputação de enviar um vinho "regular" rotulado como "bom" para o mercado internacional é altíssimo. É preferível que o modelo seja "rigoroso" e só classifique como bom aquilo que ele tem certeza absoluta.
- **Prioridade para Recall:** Em um cenário de **controle de qualidade interno (triagem)**, o Recall é prioritário. A vinícola deseja garantir que nenhum lote de vinho excelente seja descartado ou misturado com vinhos comuns por engano. O modelo atua como um filtro inicial para que enólogos humanos provem apenas o que foi pré-selecionado, minimizando o desperdício de potencial.

4.3 Q3: Camadas Ocultas e Teorema da Aproximação Universal

O Teorema da Aproximação Universal (**embasado nos estudos de Cybenko abordados por Russell e Norvig**) afirma que **uma única camada oculta com um número suficiente de neurônios é suficiente para representar qualquer função contínua**. Contudo, na prática da Engenharia de Software, redes com 2 ou 3 camadas menores tendem a performar melhor por serem mais eficientes em termos de parâmetros. Camadas sucessivas permitem o **aprendizado de representações hierárquicas**: a primeira camada aprende características simples (ex: correlação álcool/densidade), enquanto a segunda combina essas

características em abstrações mais complexas (ex: o "corpo" ou "equilíbrio" químico do vinho). Redes profundas generalizam melhor e são menos propensas a memorizar o ruído do dataset (overfitting) do que uma única camada excessivamente larga.

4.4 Q4: Validações para Produção

Antes de implantar este modelo em uma cooperativa, seriam indispensáveis:

1. **Validação de Data Drift:** Monitorar se a composição química das uvas muda significativamente entre safras (ex: um ano muito seco alterando o açúcar residual), o que exigiria retreinamento.
2. **Teste de Robustez (Análise de Erro):** Verificar como o modelo se comporta com falhas de sensores (dados nulos ou ruidosos).
3. **Shadow Deployment:** Rodar o modelo em paralelo com as avaliações humanas por um período, comparando as previsões sem que elas tomem decisões automáticas ainda.
4. **Responsabilidade Legal:** Estabelecer protocolos para "falsos positivos" que gerem reclamações de clientes, definindo a intervenção humana como última instância de decisão.

5. Conclusão

O desenvolvimento deste trabalho permitiu a aplicação prática de conceitos fundamentais de aprendizado supervisionado em um problema real e desbalanceado. A utilização de técnicas de pré-processamento, como a normalização por *StandardScaler* e o balanceamento via *Class Weights*, mostrou-se essencial para a estabilidade do treinamento.

A Rede Neural Feedforward demonstrou ser uma ferramenta superior ao baseline estatístico, atingindo um **ROC AUC de 0.8884**, o que indica uma alta capacidade de separação entre as classes. Embora o dataset seja limitado em tamanho, o uso de

regularização via **Dropout** garantiu que o modelo mantivesse uma boa capacidade de generalização, como evidenciado pela convergência das curvas de perda.

Conclui-se que a IA pode atuar como um sistema de suporte à decisão altamente eficaz na vitivinicultura, automatizando a triagem de qualidade com um nível de precisão técnica que complementa a análise sensorial humana. Para trabalhos futuros, sugere-se a coleta de mais amostras da classe positiva e a experimentação com algoritmos de *Boosting* para comparação de métricas.

6. Referências

- CORTEZ, P. et al. **Modeling wine preferences by data mining from physicochemical properties**. Decision Support Systems, 2009.
- RUSSELL, Stuart J.; NORVIG, Peter. **Inteligência artificial. 3. ed.** Rio de Janeiro: Elsevier, 2013
- UCI Machine Learning Repository: Wine Quality Dataset.
-  1-Hour Machine Learning Challenge: Predicting Wine Quality
-  Wine Quality Prediction with Scikit-Learn | Machine Learning Tutorial