

Relatório Técnico: Predição de Qualidade de Vinhos com Redes Neurais

Professor: Marcio Andrey Roselli

Estudante: Bianco Da Costa Oliveira

Bases Engenharia de Software VI - Inteligência Artificial

1. Introdução

Este relatório descreve o desenvolvimento de um modelo de Inteligência Artificial para a predição da qualidade de vinhos tintos da região do Minho, Portugal. Utilizando o dataset *Wine Quality* (Cortez et al., 2009), o objetivo principal foi converter um problema de regressão/multiclasse em uma classificação binária: vinhos "Bons" (nota ≥ 7) e vinhos "Regulares" (nota < 7). O desafio central reside no desbalanceamento dos dados, visto que vinhos de alta qualidade representam apenas cerca de 13,5% das amostras.

2. Metodologia

2.1 Pré-Processamento

Os dados passaram pelas seguintes etapas de tratamento:

- **Limpeza:** Verificação de valores ausentes (nenhum encontrado).
- **Divisão de Dados:** Separação em 80% para treinamento e 20% para teste, utilizando **estratificação** para manter a proporção das classes original em ambos os conjuntos.
- **Normalização:** Aplicação do *StandardScaler* para garantir que todos os 11 atributos físico-químicos (como álcool, pH e acidez) estivessem na mesma escala, evitando que variáveis com valores nominais maiores dominassem o aprendizado.

2.2 Arquitetura da Rede

Foi implementada uma Rede Neural Feedforward (MLP) utilizando PyTorch com a seguinte estrutura:

- **Camada de Entrada:** 11 neurônios.
- **1ª Camada Oculta:** 64 neurônios com ativação **ReLU**.
- **2ª Camada Oculta:** 32 neurônios com ativação **ReLU**.
- **Camada de Saída:** 1 neurônio (saída linear para uso com Logits).
- **Regularização:** Inclusão de camadas de **Dropout (30%)** após cada camada oculta para prevenir o *overfitting*.

2.3 Hiperparâmetros

Os parâmetros de treinamento foram selecionados para otimizar a convergência:

- **Otimizador:** Adam (taxa de aprendizado inicial de 0.001).
- **Função de Perda:** BCEWithLogitsLoss.
- **Épocas:** 100.
- **Batch Size:** 32.

Estratégias de Desbalanceamento

Foram adotadas duas estratégias principais:

1. **SMOTE (Synthetic Minority Over-sampling Technique):** Utilizado no pré-processamento para gerar amostras sintéticas da classe minoritária no conjunto de treino.
2. **Pesos de Classe (Class Weights):** Aplicação de um peso penalizador na função de perda para a classe positiva, forçando a rede a dar mais importância aos acertos dos vinhos "Bons".

3. Resultados

3.1 Tabelas Comparativas

Modelo	Acurácia Geral	Precision (Bom)	Recall (Bom)	F1-Score (Bom)
Baseline (Reg. Logística)	81%	0.40	0.79	0.53
Rede Neural (Final)	86%	0.48	0.77	0.59

3.2 Curvas de Aprendizagem

As curvas de *loss* demonstraram uma queda suave, com a perda de validação acompanhando a de treinamento, validando a eficácia do Dropout em evitar a memorização dos dados.

3.3 Matriz de Confusão

A matriz de confusão da rede neural revelou uma capacidade superior de filtrar vinhos regulares, diminuindo drasticamente o número de falsos positivos em comparação ao baseline.

3.4 ROC (Receiver Operating Characteristic)

A curva ROC apresentou uma AUC (Área sob a curva) elevada, demonstrando que o modelo possui um forte poder de discriminação entre as classes em diferentes limiares.

3.5 Precision-Recall

Dada a natureza desbalanceada, esta curva foi essencial para ajustar o modelo visando um F1-Score equilibrado, garantindo que a precisão não fosse sacrificada em excesso pelo recall.

4. Discussão

4.1 Q1: RN superou o Baseline?

Sim. A rede neural obteve uma acurácia de 86% contra 81% da Regressão Logística. O ganho em precisão (de 0.40 para 0.48) mostra que a rede neural consegue capturar interações não lineares entre os compostos químicos que um modelo linear ignora.

4.2 Q2: Trade-off Precision vs Recall

Para vinhos premium (exportação), priorizamos a **Precisão** (não rotular um vinho ruim como bom). Para uma triagem inicial em massa na vinícola, priorizamos o **Recall** (não deixar nenhum vinho bom ser descartado).

4.3 Q3: Camadas Ocultas e Teorema da Aproximação Universal

Embora uma camada possa mapear qualquer função, redes com 2 ou 3 camadas menores são mais eficientes. Elas aprendem representações hierárquicas (ex: acidez e álcool combinados na 1ª camada formam um conceito de "equilíbrio" na 2ª camada).

4.4 Q4: Validações para Produção

Antes do uso real, seriam necessários testes de **Data Drift** (verificar se o modelo funciona em safras de anos diferentes) e testes de robustez contra sensores de entrada defeituosos.

4.5 Q5: Considerações sobre Ética e Negócio

O erro do modelo impacta diretamente a receita. Um falso positivo pode gerar devoluções de lotes inteiros, enquanto um falso negativo é uma oportunidade de lucro perdida.

5. Conclusão

O projeto demonstrou que redes neurais, quando combinadas com técnicas de balanceamento (SMOTE/Pesos) e regularização, são ferramentas poderosas para a vitivinicultura. O modelo final oferece uma base sólida para automação da classificação de qualidade, com métricas superiores aos modelos estatísticos tradicionais.

6. Referências

- CORTEZ, P. et al. **Modeling wine preferences by data mining from physicochemical properties**. Decision Support Systems, 2009.
- UCI Machine Learning Repository: Wine Quality Dataset.
- Documentação oficial do PyTorch e Scikit-Learn.